

Guía de trabajos prácticos

Curso de posgrado

Redes Ecológicas: qué sabemos, qué no y por qué importa

30 de septiembre al 4 de octubre de 2025

Docentes responsables

Diego Vázquez, Instituto Argentino de Investigaciones de las Zonas Áridas, CONICET-Universidad Nacional de Cuyo; Facultad de Ciencias Exactas y Naturales, Universidad Nacional de Cuyo (Argentina); dvazquez@mendoza-conicet.gov.ar

Guadalupe Peralta, Instituto Multidisciplinario de Biología Vegetal, CONICET-Universidad Nacional de Córdoba (Argentina); gperalta@imbiv.unc.edu.ar

Docentes invitados

Matías Arim, Centro Universitario Regional del Este, Universidad de la República (Uruguay)
Luciano Cagnolo, Instituto Multidisciplinario de Biología Vegetal, CONICET-Universidad Nacional de Córdoba (Argentina)

Paul CaraDonna, Chicago Botanical Garden & Northwestern University (Estados Unidos)
Sonia Kéfi, Institut des Sciences de l'Évolution de Montpellier, CNRS, Université Montpellier, IRD (Francia)

Florencia Miguel, Instituto Argentino de Investigaciones de las Zonas Áridas, CONICET-Universidad Nacional de Cuyo (Argentina)

Alicia Montesinos, Centro de Investigaciones sobre Desertificación, CSIC-Universidad de Valencia (España)

Sergio Navarrete, Pontificia Universidad Católica de Chile (Chile)

María Pascual Tudanca, Instituto Argentino de Investigaciones de las Zonas Áridas, CONICET-Universidad Nacional de Cuyo (Argentina)

Micaela Santos, Instituto Argentino de Investigaciones de las Zonas Áridas, CONICET-Universidad Nacional de Cuyo (Argentina)

Posgrado avalante: Doctorado de Ciencia y Tecnología, Facultad de Ciencias Exactas y Naturales, Universidad Nacional de Cuyo

Índice

1. Información general sobre el curso	
1.1. Descripción general	2
1.2. Lugar de encuentro y horario	2
2. Usando el entorno R	
2.1. Breve introducción a R	3
2.2. Lectura de datos	3
2.3. Paquetes o librerías en R	3
2.4. Gráficos de redes bipartitas	4
2.5. Gráficos de redes unimodales.	4
3. Estructura de redes	
3.1. Redes bipartitas	
3.1.1. Métricas a nivel de red	5
3.1.2. Métricas a nivel de grupo	6
3.1.3. Métricas a nivel de especie	6
3.1.4. Métricas a nivel de interacción.	7
3.2. Redes unimodales	7
4. Completitud de muestreo usando coverage-based rarefaction	8
5. Análisis de robustez	11
6. Modelos nulos: qué son, cómo construirlos, cómo comparar matrices observadas con matrices originadas de un modelo nulo	
6.1 Qué son los modelos nulos	12
6.2. Qué modelo nulo elijo	12
6.3. Modelos nulos con el paquete bipartite	13
6.4. El uso de z-scores para comparar redes	15
8. Referencias	16

1. Información general sobre el curso

1.1. Descripción general

El estudio de sistemas biológicos requiere que abarquemos niveles crecientes de complejidad y diversidad. En tal sentido, el uso de herramientas y conceptos de redes ha crecido notablemente en los últimos años por lo que resulta necesario ordenar, clasificar y describir la información existente. En este curso ofrecemos una introducción al estudio de redes en ecología comenzando desde las preguntas más básicas: qué son y por qué estudiar redes en ecología. Esperamos que este curso ayude a definir si un enfoque de redes es (o no) útil para comprender la ecología de las especies, el funcionamiento y la estabilidad de las comunidades y su respuesta a los impulsores del cambio global. En términos prácticos, ofrecemos una recorrida por las herramientas más utilizadas para describir redes, detectar sus patrones estructurales y evaluar los mecanismos que los generan. Finalmente, presentamos una muestra del estado del arte en temas de vanguardia en el estudio de redes ecológicas mediante charlas a cargo de investigadores invitados. Con este curso esperamos ofrecer una reseña equilibrada de aspectos teórico-prácticos básicos sobre redes de interacciones ecológicas.

El curso consiste en clases teóricas, discusiones y prácticas de laboratorio en computadoras utilizando herramientas desarrolladas en el entorno estadístico R. Además, los estudiantes desarrollarán durante el curso un proyecto, de manera individual o grupal, que será presentado oralmente y evaluado el último día del curso. El proyecto consistirá en:

- Plantear preguntas ecológicas, hipótesis y predicciones que puedan ser abordadas usando un enfoque de redes.
- Seleccionar una base de datos con la cual abordar dichas preguntas.
- Utilizando los métodos discutidos durante el curso, desarrollar un proyecto grupal que involucre cuantificar atributos estructurales de redes, realizar análisis y/o simulaciones que permitan responder las preguntas planteadas.
- Presentar los resultados obtenidos y conclusiones, identificando futuros caminos de investigación.

La evaluación se realizará el último día del curso. Las calificaciones del curso serán entregadas dos semanas después de concluido el mismo, ya que para la obtención de las calificaciones los docentes ponderarán el proyecto desarrollado, así como la participación en clase.

1.2. Lugar de encuentro y horario

El curso se realizará del 30 de septiembre al 4 de octubre de 2025, de 9 a 17 hs en la sala Payunia del CCT CONICET Mendoza.

2. Usando el entorno R

2.1. Breve introducción a R

R es un lenguaje de programación y un entorno desarrollado con un enfoque para el análisis estadístico y la visualización de datos. Es un software de acceso libre y código abierto, inicialmente creado por Robert Gentleman y Ross Ihaka (Universidad de Auckland, Nueva Zelanda). Sitio oficial de R: <https://www.r-project.org/> ; documentos útiles:

<http://cran.r-project.org/manuals.html>

2.2. Lectura de datos

Para poder usar las funciones descritas más adelante, primero necesitamos datos. Si tenés datos de interacciones propios, podés usarlos. De lo contrario, podés descargar un set de datos de interacciones de alguna de estas bases de datos:

<http://www.ecologia.ib.usp.br/iwdb/index.html>,

<https://www.web-of-life.es/map.php> (si descargás un set de datos de la base de datos *web of life*, antes de descargar la matriz seleccioná la opción “include especies” y el formato “.csv”). Una vez que tenemos datos, existen diversas maneras de leerlos en R. Sugerimos guardar los datos como archivo .csv (ej. “datos.csv”) para leerlos con la siguiente línea de código:

```
red <- as.matrix(read.csv(file="datos.csv", row.names=1, sep=","))
#nota: es importante saber si las columnas están separadas por
comas o puntos y comas para definir el argumento sep
head(red)
class(red)
rownames(red)
colnames(red)
```

Otra opción es usar algún set de datos que trae el paquete `bipartite`. Para esto, instalá el paquete `bipartite` en R, descargalo y elegí un set de datos:

```
install.packages("bipartite")
library(bipartite)
data(package="bipartite")
red <- Safariland
```

2.3. Paquetes o librerías en R

Los paquetes o librerías en R son conjuntos de funciones, datos y documentos para el desarrollo de tareas específicas, que permiten aumentar la funcionalidad de R. Para el estudio de las redes bipartitas el paquete `bipartite` de R (Dormann et al., 2008) es la principal herramienta. Para realizar los análisis, `bipartite` necesita como objeto de entrada una matriz de interacción de $m \times n$ especies, donde m es el nivel superior (columnas) y n es el nivel inferior (filas). A continuación vemos la página de ayuda:

```
?bipartite
```

Para el estudio de redes unimodales (como la mayoría de las redes tróficas, redes espaciales, etc.), podemos utilizar el paquete `sna` (Butts 2023) de R:

```
install.packages("sna")
library(sna)
?sna
```

2.4. Gráficos de redes bipartitas

Para visualizar y explorar las relaciones de nuestra red, podemos graficarla, lo que nos brinda un panorama general de la estructura global de las interacciones en nuestra comunidad. Existen múltiples paquetes de R que pueden usarse para graficar redes. El paquete `bipartite` ofrece dos opciones de gráficas: `plotweb` y `visweb`. Por ejemplo, para graficar los datos de la red de Safariland que leímos en el punto 2.2 y que guardamos en el objeto `red`, escribimos:

```
plotweb(red)
plotweb(red, text.rot=90, arrow="down.center",
col.interaction="wheat2")

visweb(red)
visweb(red, type="nested", text="interaction")
```

Otros paquetes de R que ofrecen opciones para graficar una red bipartita son `igraph` y `circlize`. Este es un ejemplo de cómo hacerlo con `circlize`:

```
install.packages("circlize")
chordDiagram(red, annotationTrack="grid", big.gap=20)
```

2.5. Gráficos de redes unimodales

Podemos generar una red unimodal aleatoria utilizando la función `rgraph` del paquete `sna` y graficarla usando la función `gplot` del mismo paquete. La función `gplot` posee múltiples argumentos, entre ellos `gmode` que me permite indicar si el grafo a dibujar es dirigido (las aristas entre nodos tienen un sentido definido) o no dirigido (las aristas entre nodos no tienen dirección):

```
set.seed(123)
gplot(rgraph(3), gmode="digraph")
set.seed(123)
gplot(rgraph(3), gmode="graph")
```

A diferencia de las redes unimodales, en redes bipartitas, como una red planta-polinizador, los integrantes de un grupo (plantas) no pueden conectarse directamente entre sí. Sin embargo, las interacciones indirectas que ocurren entre especies de plantas por interactuar con las mismas especies de polinizadores, pueden ser utilizadas para crear una red unimodal de plantas. Es decir, podemos generar una red unimodal (de plantas) en la cual establezcamos vínculos entre nodos (especies de plantas) cuando éstos se encuentran vinculados con los mismos nodos del otro grupo (i.e., una especie de planta tiene un vínculo con otra especie de planta si ambas son visitadas por una misma especie de polinizador). Para crear una red unimodal (ej. de plantas) a partir de una red bipartita (ej. red planta-polinizador), podemos utilizar la función `as.one.mode` del paquete `bipartite`:

```
as.one.mode(Safariland, project="lower")
```

Podemos graficar las dos redes unimodales que se pueden obtener de una red bipartita de la siguiente manera:

```
gplot(as.one.mode(Safariland, project="lower"),
      label=rownames(Safariland), gmode="graph",
      label.cex=0.6, vertex.col="lightgreen")
gplot(as.one.mode(Safariland, project="higher"),
      label=rownames(Safariland), gmode="graph",
      label.cex=0.6, vertex.col="orange")
```

3. Estructura de una red

3.1. Red bipartita

En el paquete `bipartite`, hay cuatro niveles en los que podemos evaluar los atributos estructurales de una red bipartita: a nivel de toda la red (función `networklevel`), a nivel de los grupos superiores e inferiores (e.g., para dispersores y plantas; función `grouplevel`), a nivel de las especies (función `specieslevel`) y a nivel de los links (función `linklevel`).

3.1.1. Métricas a nivel de toda la red

La función `networklevel` brinda información general sobre la red y calcula estadísticos para toda la red, como el anidamiento, la conectancia, la modularidad y la especialización a nivel de la red. La ayuda de la función provee la información de todas las métricas que pueden calcularse con la misma:

```
?networklevel
```

Dentro de la función `networklevel`, el argumento `index` define qué métricas quiero calcular, por ejemplo:

```
networklevel(red, index=c("connectance", "interaction evenness"))
```

o podemos calcular todas las métricas la red (en este caso excluyendo el ajuste de la distribución del grado):

```
networklevel(red, index="ALLBUTDD")
```

Para estimar modularidad, determinar qué especies pertenecen a cada módulo y graficar los módulos:

```
mod_red <- computeModules(red, method="Beckett", deep=FALSE,
deleteOriginalFiles=FALSE, steps=1000, tolerance=1e-10,
experimental=FALSE, forceLPA=FALSE)
mod_red@likelihood
```

```
listModuleInformation(mod_red)
printoutModuleInformation(mod_red)
plotModuleWeb(mod_red)
```

Como vamos a ver más abajo (métricas a nivel de especie), el análisis de modularidad también sirve para analizar los roles estructurales de las especies en la red.

ACTIVIDAD: Graficar la red, estimar métricas de interacciones y compararlas con las obtenidas por un colega. ¿Qué significan esas diferencias? ¿Es correcto comparar esas métricas entre redes de distintos trabajos? Discutir en grupo.

3.1.2. Métricas a nivel de grupo

La función `grouplevel` calcula estadísticos a nivel de cada grupo de especies de la red. Por ejemplo, en una red de interacciones entre plantas y polinizadores, la función da información sobre el grupo plantas y sobre el grupo polinizadores. Si bien la función `grouplevel` puede ser usada por sí sola, suele invocarse a través de la función `networklevel`. En la página de ayuda de `grouplevel` o de `networklevel` podemos ver la lista completa de índices que se pueden obtener mediante esta función:

```
?grouplevel
?networklevel
```

Por ejemplo, para calcular el número de especies y el solapamiento de nicho de las especies de los diferentes grupos de nuestra red bipartita, escribimos:

```
networklevel(red, index=c("number of species", "niche overlap"),
level="higher")
networklevel(red, index=c("number of species", "niche overlap"),
level="lower")
networklevel(red, index=c("number of species", "niche overlap"),
level="both")
```

3.1.3. Métricas a nivel de especie

Para cada especie de la red, la función `specieslevel` incluye una serie de índices como el grado (opción `index="degree"`), grado normalizado (ND), diversidad de Shannon de las interacciones de cada especie (`diversity`), y estadísticos de centralidad que caracterizan la posición de cada especie en la red (`betweenness`, `closeness`), entre otros. En la página de ayuda de `specieslevel` podemos ver la lista completa:

```
?specieslevel
```

Por ejemplo, si queremos conocer el grado y la centralidad de las especies, podemos hacer:

```
specieslevel(red, index=c("degree", "closeness"), level="higher")
specieslevel(red, index=c("degree", "closeness"), level="lower")
specieslevel(red, index=c("degree", "closeness"), level="both")
specieslevel(red, index="ALLBUTD")
```

Para calcular los roles estructurales de las especies, podemos utilizar los coeficientes *z* (conectividad intra-modular) y *c* (coeficiente de participación) resultantes del análisis de modularidad (ver Olesen et al. 2007):

```
zc_saf_plant <- czvalues(mod_web, weighted=TRUE, level="lower")
zc_saf_plant

zc_saf_poll <- czvalues(mod_web, weighted=TRUE, level="higher")
zc_saf_poll
```

ACTIVIDAD: Estimar métricas a nivel de especie. ¿Qué significan esas diferencias entre distintas especies? ¿Es correcto comparar esas métricas entre especies de una misma red? ¿Y entre especies de redes diferentes? Discutir en grupo.

3.2. Redes unimodales

El paquete `sna` ofrece varias herramientas para estudiar las características estructurales de las redes unimodales. Como su nombre lo indica (`sna`: Social Network Analysis), este paquete ha sido desarrollado para el estudio de las redes sociales humanas, aunque las herramientas allí presentes sirven también para otras áreas de estudio como la biología y la ecología. Por ejemplo, podemos usar la función `gden` para calcular la conectancia de la red unimodal entre plantas construída a partir de los datos `Safariland`:

```
red2 <- as.one.mode(Safariland, project="lower")
gden(red2)
```

Asimismo, podemos calcular el grado (número de enlaces interespecíficos) de cada nodo que, en el caso de `red2`, representaría el número de especies de plantas con las que cada planta comparte polinizadores. El argumento `gmode` de la función `degree` permite definir si se trata de una red dirigida (los enlaces tienen una dirección específica) o no (los enlaces no tienen una dirección definida), usando `digraph` o `graph`, respectivamente. En este ejemplo, tenemos una red no dirigida:

```
degree(red2, gmode="graph")
```

En redes dirigidas, el argumento `cmode` permite calcular el número de enlaces dirigidos al nodo (`cmode="indegree"`) y el número de enlaces que salen del nodo (`cmode="outdegree"`):

```
degree(red2, cmode="indegree")
degree(red2, cmode="outdegree")
```

Considerando los caminos que unen a las especies en una red, podemos evaluar la distancia a la que se encuentran un par de especies promedio y detectar especies o nodos con roles no redundantes en el recorrido de dichos caminos. La distancia entre un par de especies consiste en contar el número de vínculos que debe atravesarse para unirlos, por el

camino más corto. Con esta información es posible calcular diferentes índices de centralidad de las especies dependiendo que nos enfoquemos en el número de caminos más cortos que concentra una especie o nodo (centralidad de cercanía o *closeness centrality*) o el número de veces que un nodo actúa como puente para los caminos más cortos de otros nodos (centralidad de intermediación o *betweenness centrality*). Conceptualmente, nodos con alta centralidad de cercanía (*closeness centrality*) tienen, en promedio, caminos más cortos para llegar a todos los otros nodos de la red. Por otro lado, nodos (especies) con alta centralidad de intermediación (*betweenness centrality*) están ubicados en un gran número no-redundante de vías más cortas (*shortest paths*) entre otros nodos, sirviendo de puentes entre otras especies. Conocer la distancia promedio a la que se encuentran las especies en una red de interacciones permitiría evaluar cuán interconectadas están las dinámicas poblacionales e inferir la velocidad de propagación de las perturbaciones (Williams et al., 2002). Por otra parte, los índices de centralidad son utilizados para encontrar especies clave en las comunidades (Jordán, 2007; Sazima et al., 2010).

Para calcular la centralidad de cercanía e intermediación:

```
closeness(red2, gmode="graph")
betweenness(red2, gmode="graph")
```

4. Completitud de muestreo usando coverage-based rarefaction

La completitud del muestreo (o cobertura del muestreo) describe en qué medida una muestra refleja la diversidad real de una comunidad incluyendo a las especies que no se detectaron en el muestreo. Es decir, la completitud del muestreo estima la proporción de individuos de la comunidad (en su conjunto) que pertenecen a especies presentes en la muestra (Roswell et al., 2021). Calcular la completitud de nuestra muestra nos permite saber qué tan bien hemos capturado la diversidad de la comunidad y nos permite, además, tomar algunas decisiones. Por ejemplo, si necesitamos continuar con el esfuerzo de muestreo o si podemos comparar redes construidas a partir de dos muestreos diferentes.

Para calcular la completitud de una muestra vamos a utilizar el paquete *iNEXT* (Hsieh et al., 2016). Este paquete se centra en las tres medidas de los números de Hill: riqueza ($q = 0$), diversidad de Shannon-Hill ($q = 2$) y diversidad de Simpson-Hill ($q = 3$). Este paquete usa la muestra observada para calcular las estimaciones de diversidad (junto con sus intervalos de confianza) y permite graficar la curva de completitud de muestreo. Esta curva representa gráficamente las estimaciones de diversidad con respecto a la cobertura de la muestra.

Para poder graficar nuestras curvas de completitud de la muestra vamos a utilizar dos funciones del paquete *iNEXT* de R: *iNEXT* y *ggiNEXT*. La primera función estima las tres métricas de diversidad de Hill y soporta tres tipos de bases de datos:

1. Datos de abundancia basados en individuos (`datatype="abundance"`);
2. Datos de incidencia basados en unidades de muestreo:
 - a. Datos brutos de incidencia (`datatype="incidence_raw"`);
 - b. Datos de incidencia-frecuencia (`datatype="incidence_freq2"`).

La segunda función, `ggiNEXT`, gráfica las curvas de completitud utilizando los números de Hill.

Entonces, para poder graficar nuestras curvas de completitud primero instalamos el paquete:

```
install.packages("iNEXT")  
library("iNEXT")
```

Para esta actividad vamos a trabajar con un set de datos de censos de visitas a las flores que se realizaron de 2006 a 2011 en la Reserva Natural Villavicencio (Chacoff et al., 2018). Para eso vamos a cargar en R el archivo `chacoff_etal_2018_sitios.csv` que muestra el número de visitas que recibió cada especie de planta en cada uno de los sitios de muestreo (cuatro sitios: V1, V2, V3 y V4):


```
web.chacoff <-  
as.matrix(read.csv(file="chacoff_etal_2018_sitios.csv",  
row.names=1))
```

Luego, calculamos los números de Hill utilizando nuestra matriz de interacciones:

```
out <- iNEXT(web.chacoff, q=c(0,1,2), datatype="abundance")
```

Y finalmente graficamos:


```
ggiNEXT(out, type=2)
```



El argumento `facet.var` de la función `ggiNEXT` nos permite crear un gráfico independiente para cada valor de una variable específica. Por ejemplo, podemos separar el


gráfico según los sitios ("Assemblage") para ver si la completitud del muestreo es la misma para cada sitio:

```
ggiNEXT(out, type = 2, facet.var = "Assemblage")
```



Con el argumento `facet.var` también podemos ver la diferencia en los índices de diversidad ("Order.q") en cada uno de los sitios:

```
ggiNEXT(out, type=1, facet.var="Order.q")
```



ACTIVIDAD: Calcular la completitud de muestreo de una red. ¿Se necesita continuar con el esfuerzo de muestreo?

5. Robustez

La robustez de una red es una medida de la tolerancia que posee la misma a la extinción secundaria de especies, por lo que una red es más robusta cuando experimenta menor cantidad de extinciones secundarias luego de perder una o más especies (Dunne et al. 2002). Las extinciones primarias pueden ser de plantas o de animales y tener un orden específico o no, por ejemplo de las más a menos conectadas o extinciones aleatorias. Esta medida nos sirve para simular el efecto de la pérdida de especies y comparar entre distintos escenarios o incluso entre redes diferentes.

Para calcular la robustez de una red, primero usamos la función `second.extinct` para calcular el número de extinciones secundarias frente a una secuencia particular o aleatoria de pérdida de especies y luego, usamos la función `robustness` para calcular el área bajo la curva de extinción generada. La forma y la pendiente de la curva de extinción nos sirve para interpretar visualmente la fracción de especies remanentes frente a cada remoción primaria y podemos graficarla mediante la función `slope.bipartite`. Además, podemos obtener un valor de R (el área bajo la curva) que nos indica si la red globalmente es robusta (tiende a 1) o frágil (tiende a 0) usando la función `robustness`.

Para la actividad vamos a utilizar algún set de datos del paquete `bipartite` (ej. "memmott1999") para simular extinciones primarias de plantas en orden aleatorio y según su grado (número de interacciones) y calcular las extinciones secundarias de los visitantes florales:

```
data("memmott1999")
```

```
ex1 <- second.extinct(memmott1999, participant="lower",  
method="random", nrep=50, details=FALSE)
```

```
ex2 <- second.extinct(memmott1999, participant="lower",  
method="degree", nrep=50, details=FALSE)
```

Luego, vamos a graficar las curvas de extinción y calcular los valores de robustez:

```
slope.bipartite(ex1)  
robustness(ex1)
```

```
slope.bipartite(ex2)  
robustness(ex2)
```

ACTIVIDAD: Calcular la robustez de una red frente a extinciones aleatorias de plantas y según el grado ¿Frente a qué orden de extinción la red es más robusta?

6. Modelos nulos

6.1 Qué son los modelos nulos

Los modelos nulos son una técnica utilizada en ecología para generar un patrón de datos (como un patrón de interacción entre especies) en ausencia de un mecanismo de interés, que luego es comparado con los datos originales (Gotelli & Graves, 1996). Los modelos nulos son simulaciones numéricas basadas en la aleatorización de los datos (Manly, 2007) de acuerdo con alguna regla que controla el nivel en el que se aplica la aleatorización (por ejemplo, a nivel de individuos o de especies en una comunidad) y otras restricciones en la forma en que se reasignan los contenidos de la matriz comunitaria original.

R tiene varias herramientas útiles para realizar análisis de modelos nulos. Por ejemplo, el paquete `stats` contiene la función `r2dtable` para aleatorizar una matriz conservando las sumas marginales de la matriz, `bipartite` incluye la función `nullmodel` que implementa varios de los modelos nulos más comunes en la literatura para redes de interacción, el paquete `vegan` (disponible con la instalación de `bipartite`) tiene varias funciones adicionales (algunas de las cuales representan modelos nulos equivalentes a los implementados en `bipartite`). Otro paquete de R para realizar análisis de modelos nulos es `econullnetr` (Vaughan et al. 2017).

6.2 ¿Qué modelo nulo elijo?

Qué modelo nulo decidamos usar dependerá de nuestras preguntas de investigación: los mecanismos ecológicos que nos interese evaluar como responsables de los patrones observados en nuestra red. Entonces, como siempre, lo esencial es tener claras nuestras preguntas; una vez que eso esté claro, podemos buscar un modelo nulo que nos permita evaluar los mecanismos involucrados. Por ejemplo, si nos interesa evaluar si los atributos de las especies en su conjunto pueden generar los patrones observados en nuestra red, podemos comparar el patrón observado en nuestra red con el generado por un modelo nulo que excluya *todos* los atributos de las especies; es decir, un modelo nulo en el que todas las especies tengan la misma probabilidad de interactuar, independientemente de sus atributos, algo que podemos hacer fácilmente con la función `mgen` (Vázquez et al. 2009).

Alternativamente, si nos interesa evaluar el papel de las diferencias en los atributos más allá de las diferencias en el número de interacciones de cada especie, podemos utilizar un modelo nulo que preserve el total de interacciones de cada especie (los totales marginales de filas y columnas de la matriz de interacción), como `r2table` o `vaznull` del paquete `bipartite`. O podría interesarnos evaluar si la abundancia de las especies, los rasgos morfológicos y la fenología explican el patrón de red (o, dicho de otro modo, si los mecanismos que generan el patrón observado incluyen otros atributos más allá de la abundancia, la morfología y la fenología), y en ese caso podríamos combinar matrices de probabilidades de interacción esperadas según estos atributos y usar la función `mgen` como modelo nulo.

6.3 Modelos nulos con el paquete bipartite

El paquete `bipartite` incluye cinco funciones para modelos nulos: `r2dtable`, `swap.web`, `vaznull`, `shuffle.web` y `mgen`. La función `nullmodel` engloba estas cinco funciones como opciones. La opción `r2dtable` genera matrices aleatorizadas según un algoritmo que distribuye aleatoriamente las interacciones en las celdas de la matriz con probabilidad proporcional a los totales marginales de filas y columnas, manteniendo fijos esos totales pero sin mantener fija la conectancia (Patefield 1981). La opción `swap.web` genera matrices aleatorizadas manteniendo los totales marginales y, a diferencia de `r2dtable`, manteniendo fija también la conectancia. El método que se usa para aleatorizar las matrices en `swap.web` genera ciertos sesgos, lo que lo hace un método poco recomendable para el análisis de modelos nulos (ver ayuda de `swap.web` en `bipartite` y Blüthgen & Staab 2024). La opción `vaznull` implementa un modelo nulo utilizado por Vázquez et al. (2007) que distribuye las interacciones en forma proporcional a los totales marginales de la matriz pero sin requerir que esos totales en las matrices aleatorizadas sean iguales a los de la matriz original, y requiriendo que la conectancia sea igual a la observada. Por su parte, `shuffle.web` genera matrices parecidas a las generadas por `vaznull`, en las que las sumas marginales no son fijas pero sí lo es la conectancia. Finalmente, la opción `mgen` implementa el algoritmo de Vázquez et al. (2009) que permite generar modelos nulos a partir de matrices de probabilidad de interacción que representan distintos mecanismos (ver más abajo).

Por ejemplo, para generar 1000 matrices aleatorizadas con `nullmodel` usando la opción `vaznull` a partir de la red de Mosquin (1967) y guardar el resultado en un objeto llamado `mos.null`, escribimos

```
library(bipartite)
data(mosquin1967)
mos.null <- nullmodel(mosquin1967, N=1000, method="vaznull")
```

El objeto `mos.null` contiene 1000 matrices de interacción aleatorizadas por el modelo nulo `vaznull`. Si alternativamente quisiéramos usar el modelo de Patefield (1981), reemplazaríamos `vaznull` por `r2dtable` en la opción `method` de `nullmodel`. Luego podemos calcular alguna propiedad de la matriz original de Mosquin (1967) y compararla con la calculada para las matrices aleatorizadas según este modelo nulo. Vamos a ver un ejemplo para el cálculo del anidamiento. Para esto necesitamos realizar el cálculo de esa propiedad repetidamente usando un bucle `for`, que realiza el cálculo para cada uno de los valores de una variable que funciona como contador, que en el ejemplo llamaremos `i` (pero puede tener cualquier nombre). Para esto primero creamos un vector llamado `mos.null.nestedness` con ceros en cada uno de sus 1000 elementos para guardar cada uno de los valores de anidamiento calculado para cada matriz aleatorizada por el modelo nulo:

```
mos.null.nestedness <- array(0,1000)
```

Luego corremos el bucle `for`:

```
for(i in 1:1000){
  mos.null.nestedness[i] <- nested(mos.null[[i]],
method="NODF")
}
```

Entonces, con el bucle `for` calculamos para cada valor de `i` entre 1 y 1000 el anidamiento para la matriz aleatorizada número `i` de `mos.null`, guardando el resultado en el elemento `i` del vector `mos.null.nestedness`. Ahora podemos calcular el intervalo de confianza del 95% (es decir, para los límites de 2.5% y 97.5% de la distribución de valores) de estos valores de anidamiento para las matrices aleatorizadas utilizando la función `quantile`:

```
quantile(mos.null.nestedness, prob=c(0.025,0.975))
```

Y finalmente comparamos los valores del modelo nulo con los de la matriz original:

```
nested(mosquin1967, method="NODF")
```

Vemos que el intervalo de confianza calculado para el modelo nulo comprende el valor de NODF calculado para la matriz original, por lo que concluimos que el anidamiento en esta matriz puede ser explicado por los procesos aleatorios supuestos por este modelo nulo.

Como alternativa al modelo `vaznull`, la función `mgen` toma una matriz de probabilidades que indica la probabilidad de interacción de cada par de especies en la comunidad. Utilizando estas probabilidades, el algoritmo distribuye `n` interacciones, construyendo una matriz binaria o cuantitativa. Por ejemplo, el modelo más simple de construcción aleatoria de una matriz es uno en el que la probabilidad de interacción es la misma para todas las especies. Si la matriz tiene `I` filas y `J` columnas, la probabilidad de interacción de una especie de planta `i` con un animal `j` es $c_{ij} = 1/(IJ)$. Imaginemos que queremos construir una matriz binaria de interacción para una comunidad de `I` = 10 plantas y `J` = 6 animales, con `L` = 15 interacciones totales. Para construir una matriz de probabilidades para esa comunidad escribimos

```
I <- 10
J <- 6
pmat <- matrix(1/(I*J), I, J)
```

Luego usamos `mgen` para construir la matriz de interacciones `imat`:

```
L=15
imat <- mgen(pmat, L)
```

Como mencionamos más arriba, la función `mgen` puede ser utilizada para incluir información sobre las especies, como la abundancia, la fenología, la distribución espacial y las características fenotípicas. Por ejemplo, consideremos un modelo nulo en el que la probabilidad de interacción es proporcional a la abundancia relativa de las especies. Imaginemos, para simplificar, que las sumas marginales de la matriz cuantitativa están

correlacionadas con la abundancia. Entonces, la abundancia relativa de las plantas para la red de Mosquin (1967) es

```
pla.ab <- rowSums(mosquin1967)/sum(mosquin1967)
```

y para los polinizadores

```
pol.ab <- colSums(mosquin1967)/sum(mosquin1967)
```

La matriz de probabilidades de interacción es

```
pmat <- pla.ab %*% t(pol.ab)
```

Es decir, estamos usando multiplicación de matrices (simbolizado en R como `%*%`) para multiplicar el vector de abundancias relativas de plantas por la transpuesta del vector de abundancias relativas de polinizadores, para obtener una matriz en la que cada elemento contiene la abundancia relativa de una planta i multiplicada por la abundancia de un polinizador j . Finalmente, calculamos el número total de interacciones, `i.tot`, para la matriz cuantitativa y utilizamos nuevamente `mgen` para calcular la matriz de interacciones aleatorizada:

```
i.tot <- sum(mosquin1967)
mgen(pmat, i.tot, keep.species=TRUE, rep.cell=TRUE)
```

Como en el ejemplo anterior con `vaznull`, normalmente estamos interesados en generar varias matrices aleatorizadas para comparar con la matriz observada. Para eso podemos usar el bucle `for` del mismo modo que lo usamos más arriba para el modelo `vaznull`.

```
mos.mgen <- nullmodel(mosquin1967, N=1000, method="mgen")
mos.null.nestedness <- array(0,1000)
for(i in 1:1000){
  mos.null.nestedness[i] <- nested(mos.mgen[[i]],
method="NODF")
}
quantile(mos.null.nestedness, prob=c(0.025,0.975))
nested(mosquin1967, method="NODF")
```

En este caso vemos que el anidamiento de la matriz observada (11.46) está por debajo del intervalo de confianza generado por el modelo nulo ([18.65, 33.09]), lo que lleva a la conclusión de que la matriz de Mosquin (1967) está menos anidada que lo esperado según este modelo nulo.

6.4. El uso de z-scores para comparar redes

Como vimos en la sección anterior, normalmente uno puede comparar la métrica de la red observada con la media más el intervalo de confianza obtenido por los modelos nulos. Sin embargo, a veces uno quiere saber si hay diferencias entre redes generadas a partir de diferentes sitios, por ejemplo, sitios con diferentes manejos. Podríamos comparar

directamente las métricas de las redes, sin embargo, gran parte de las métricas dependen del tamaño de las redes y el esfuerzo de muestreo. Una forma de resolver este problema es estandarizar las métricas observadas utilizando los z-scores:

$$z = (X_{\text{obs}} - X_{\text{nulo}}) / SD_{\text{nulo}}$$

Donde,

X_{obs} : valor observado de la métrica

X_{nulo} : valor medio de la métrica obtenida de los modelos nulos

SD_{nulo} : desviación estándar de los modelos nulos.

ACTIVIDAD: A partir de los datos crudos de Chacoff et al., 2018 (chacoff_etal_2018.csv) construir dos redes: una para el sitio V1 y otra para el sitio V4. Calcular la conectancia de las redes y construir modelos nulos usando la función vaznull. Luego comparar la conectancia de la red utilizando los z-score.

8. Referencias

- Blüthgen, N. & Staab, M. (2024) A critical evaluation of network approaches for studying species interactions. *Annual Review of Ecology, Evolution, and Systematics*, 55, 65-88
- Butts, C. T. (2023). *_sna: Tools for Social Network Analysis_*. R package version 2.7-2, <<https://CRAN.R-project.org/package=sna>>.
- Chacoff, N. P., Resasco, J., & Vázquez, D. P. (2018) Interaction frequency, network position, and the temporal persistence of interactions in a plant–pollinator network. *Ecology*, 99, 21-28.
- Dormann, C. F., Gruber, B. & Fründ, J. (2008) Introducing the bipartite Package: Analysing Ecological Networks. *R news*, 8, 8-11.
- Dunne, J. A., Williams, R. J. & Martinez, N. D. (2002) Network structure and biodiversity loss in food webs: robustness increases with connectance. *Ecology Letters*, 5, 558-567.
- Hsieh, T. C., Ma, K. H. & Chao, A. (2016) iNEXT: An R package for interpolation and extrapolation of species diversity (Hill numbers).
- Jordán, F. (2007). Quantifying positional importance in food webs: A comparison of centrality indices. *Ecological Modelling*, 205, 270-275.
- Mommott, J., Waser, N. M., & Price, M. V. (2004) Tolerance of pollination networks to species extinctions. *Proceedings of the Royal Society of London. Series B: Biological Sciences*, 271, 2605-2611.
- Mosquin, T. & Martin, J. E. H. (1967) Observations on the pollination biology of plants on Melville Island, N.W.T., Canada. *Canadian Field Naturalist*, 81, 201-205.
- Patefield, W. M. (1981) Algorithm AS159. An efficient method of generating $r \times c$ tables with given row and column totals. *Applied Statistics*, 30, 91-97.
- Roswell, M., Dushoff, J., & Winfree, R. (2021) A conceptual guide to measuring species diversity. *Oikos*, 130, 321-338.
- Sazima, C., Guimarães Jr, P. R., dos Reis, S. & Sazima, I. (2010). What makes a species central in a cleaning mutualism network? *Oikos*, 119, 1319-1325.

- Vaughan, I. P., Gotelli, N. J., Memmott, J., Pearson, C. E., Woodward, G., Symondson, W. O. C. (2018) econullnetr: An r package using null models to analyse the structure of ecological networks and identify resource selection. *Methods in Ecology and Evolution*, 9, 728–733.
- Vázquez, D. P., Melián, C. J., Williams, N. M., Blüthgen, N., Krasnov, B. R. & Poulin, R. (2007) Species abundance and asymmetric interaction strength in ecological networks. *Oikos*, 116, 1120-1127.
- Vázquez, D. P., Chacoff, N. P. & Cagnolo, L. (2009) Evaluating multiple determinants of the structure of plant–animal mutualistic networks. *Ecology*, 90, 2039-2046.
- Williams, R. J., Berlow, E. L., Dunne, J. A., Barabasi, A.-L. & Martinez, N. D. (2002). Two degrees of separation in complex food webs. *Proceedings of the National Academy of Sciences of the United States of America*, 99, 12913-12916.